Efrei – Université Paris Panthéon-Assas

PROJET MACHINE LEARNING

Classification de la qualité du vin à partir de mesures physico-chimiques

Rapport technique

Étudiant	Zakaria Hentabli
Professeur	Ahmed-Ghazi Blaiech
Cours	Machine Learning 1
Année universitaire	2026-2027
Date	14/10/2026

Résumé

Ce rapport décrit la construction d'un modèle de classification supervisée destiné à prédire si un vin est « bon » (note de qualité supérieure ou égale à 7) à partir de onze mesures physico-chimiques issues du jeu de données Wine Quality de l'UCI. Les vins rouges (1 599 observations) et blancs (4 898 observations) sont traités séparément. Le prétraitement comprend la suppression des doublons exacts, la conservation des valeurs aberrantes atténuées par une transformation logarithmique, la gestion du déséquilibre des classes par pondération et l'application de trois méthodes de sélection de variables. Six modèles (régression logistique, Naive Bayes gaussien, k plus proches voisins, arbre de décision, SVM linéaire et SVM à noyau gaussien) sont comparés par validation croisée stratifiée, puis réglés par Grid Search et Random Search et évalués par validation croisée imbriquée. La régression logistique régularisée, avec un seuil de décision réglé par validation croisée, est retenue pour les deux types de vin. Sur le jeu de test, utilisé une seule fois, elle atteint une AUC de 0,892 et un F1 de 0,565 pour le vin rouge, et une AUC de 0,835 et un F1 de 0,577 pour le vin blanc.

Mots-clés : classification binaire, déséquilibre des classes, validation croisée imbriquée, régression logistique, optimisation des hyperparamètres.

1 Introduction

1.1 Contexte et objectif

La qualité d'un vin dépend de nombreux paramètres physico-chimiques : acidité, pH, teneur en alcool, sucre résiduel, dioxyde de soufre, etc. L'objectif est de développer un modèle de classification supervisée capable de prédire la qualité d'un vin à partir de ces caractéristiques mesurables. Conformément à l'énoncé, le problème est binaire : un vin dont la note est supérieure ou égale à 7 est « bon », les autres sont « mauvais ».

1.2 Données

Deux fichiers sont fournis : `winequality-red.csv` et `winequality-white.csv`, accompagnés de `winequality.names` qui décrit les variables. Chaque observation comporte onze variables explicatives continues (acidité fixe, acidité volatile, acide citrique, sucre résiduel, chlorures, SO_2 libre et total, densité, pH, sulfates, alcool) et une note entière. Le Tableau 1 résume les volumes, l'équilibre des classes et le découpage apprentissage/test.

Tableau 1 – Volumes, proportion de « bons » vins et découpage stratifié 80/20

Jeu	Lignes brutes	Doublons exacts	Conservées	Bons vins	Acc. « tout mauvais »	Apprentissage	Test	Bons vins (test)
Vin rouge	1 599	240 (15,0 %)	1 359	13,5 %	86,5 %	1 087	272	37
Vin blanc	4 898	937 (19,1 %)	3 961	20,8 %	79,2 %	3 168	793	165

1.3 Démarche

Tout le code est dans le notebook `projet.ipynb`. Le rapport suit l'ordre de l'énoncé (prétraitement, modélisation, évaluation, optimisation), puis discute les limites, les éléments bonus et conclut ; l'annexe A relie chaque exigence à la section qui la traite. Les vins rouges et blancs sont analysés séparément : leurs distributions diffèrent nettement (§ 2.1) et les variables liées à la qualité ne sont pas les mêmes (§ 2.6). Un essai sur le jeu fusionné avec une indicatrice du type de vin donne à la régression logistique une AUC de 0,860 (rouges) et 0,815 (blancs), contre 0,872 et 0,822 pour les modèles séparés : l'analyse séparée est conservée.

2 Prétraitement des données

2.1 Chargement et statistiques descriptives

Chaque fichier est chargé avec le séparateur « ; ». Les statistiques descriptives (effectif, moyenne, écart-type, quartiles, extrêmes, asymétrie) sont calculées par type de vin. Le Tableau 2 compare les médianes des variables qui distinguent le plus les deux types.

Tableau 2 – Médianes de quelques variables selon le type de vin (données brutes)

Variable	SO_2 total (mg/L)	SO_2 libre (mg/L)	Sucre rés. (g/L)	Sulfates (g/L)	Chlorures (g/L)	Acid. volatile (g/L)	Alcool (% vol.)
Vin rouge	38,0	14,0	2,2	0,62	0,079	0,52	10,2
Vin blanc	134,0	34,0	5,2	0,47	0,043	0,26	10,4
Rapport blanc / rouge	3,53	2,43	2,36	0,76	0,54	0,50	1,02

Le vin blanc contient nettement plus de sucre résiduel et de SO_2 ; le rouge davantage de chlorures, de sulfates et d'acidité volatile. Plusieurs variables sont fortement asymétriques à droite (en rouge : 5,68 pour les chlorures, 4,54 pour le sucre résiduel, 2,43 pour les sulfates), ce qui justifie l'analyse séparée et la transformation logarithmique (§ 2.3).

2.2 Valeurs manquantes et doublons

Valeurs manquantes. Aucune dans les deux fichiers : aucune imputation n'est appliquée, une imputation inutile ne pouvant qu'ajouter du bruit.

Doublons. Entre 15 % et 19 % des lignes sont des doublons exacts. Ils sont supprimés avant le découpage : un doublon dans l'apprentissage et son jumeau dans le test gonfleraient artificiellement les scores, surtout pour le k-NN et l'arbre. L'effet est mesuré avec un même pipeline k-NN (k = 5) évalué par validation croisée avec et sans doublons (Tableau 3).

Tableau 3 – Effet des doublons sur un k-NN (k = 5), validation croisée sur l'apprentissage

Jeu	Doublons	Effectif	F1	AUC	Rappel
Vin rouge	conservés	1 279	0,482	0,821	0,431
Vin rouge	supprimés	1 087	0,399	0,791	0,346
Vin blanc	conservés	3 918	0,555	0,828	0,512
Vin blanc	supprimés	3 168	0,484	0,792	0,430

Les scores avec doublons sont systématiquement plus élevés : c'est une estimation optimiste, pas un meilleur modèle, ce qui confirme le dédoublonnage. Après celui-ci, aucun vecteur de variables identique ne porte deux notes différentes. Les quasi-doublons ne sont pas détectés (limite rappelée en § 6).

2.3 Valeurs aberrantes et transformation logarithmique

Les valeurs aberrantes sont détectées par la règle 1,5 × IQR calculée sur l'apprentissage et visualisées par boîtes à moustaches. Environ 25,4 % des vins rouges et 18,3 % des blancs en présentent au moins une. En rouge, les bons vins sont plus souvent atypiques (29,9 %), notamment en sucre résiduel, densité et alcool ; en blanc, les valeurs aberrantes concernent surtout les mauvais vins (chlorures, acide citrique, acidité volatile) et sont donc informatives.

Ces valeurs sont des mesures réelles ; les supprimer retirerait une part importante du jeu et une partie du signal de la classe minoritaire. Elles sont conservées et leur influence est réduite par un logarithme appliqué aux variables strictement positives dont l'asymétrie (sur l'apprentissage) dépasse 1 en valeur absolue. Sont exclus : la densité (plage très étroite autour de 1), le pH (déjà logarithmique) et l'acide citrique (contient des zéros). Le logarithme simple est préféré à log(1 + x), quasi linéaire pour de petites valeurs comme les chlorures (Tableau 4).

Tableau 4 – Asymétrie avant → après logarithme (apprentissage) ; « n.t. » = non transformé

Variable	Sucre résiduel	Chlorures	SO_2 libre	SO_2 total	Sulfates	Acidité volatile
Vin rouge	4,62 → 1,77	5,46 → 1,74	1,29 → −0,19	1,57 → −0,08	2,36 → 0,99	0,79 (n.t.)
Vin blanc	1,43 → −0,07	4,74 → 1,26	1,74 → −0,90	0,45 (n.t.)	0,95 (n.t.)	1,69 → 0,20

Le logarithme est sans état (aucun paramètre appris) et n'introduit aucune fuite ; il est suivi d'un `StandardScaler` appris dans le pipeline. Un `RobustScaler` donne des résultats identiques pour la régression logistique (AUC 0,872 en rouge, 0,822 en blanc) ; seul le k-NN rouge en profite légèrement (AUC 0,818 contre 0,791). Le `StandardScaler` est retenu par défaut et le choix du scaler est laissé à la recherche d'hyperparamètres du k-NN (§ 5).

2.4 Variables catégorielles

Les onze variables sont numériques continues : aucun encodage n'est nécessaire pour les jeux séparés. Seul l'essai fusionné ajoute une indicatrice binaire du type (1 = rouge, 0 = blanc), qui n'introduit aucun ordre artificiel.

2.5 Variable cible et équilibre des classes

La cible est `good = 1` si la note est ≥ 7, 0 sinon ; la note d'origine, qui contient la cible, est retirée des variables explicatives (Figure 1).

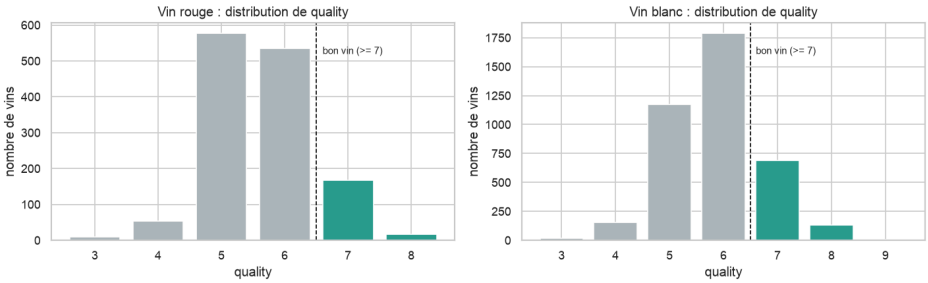


Figure 1 – Distribution des notes (rouges à gauche, blancs à droite) ; la ligne pointillée sépare les « bons » vins (note ≥ 7)

La classe 6, la plus nombreuse, jouxte le seuil : la frontière entre les notes 6 et 7 est peu marquée, ce qui limite la performance atteignable. Le jeu est aussi déséquilibré (Tableau 1) : un classifieur prédisant toujours « mauvais » obtient 86,5 % (rouge) et 79,2 % (blanc) d'accuracy sans détecter aucun bon vin. Trois mesures sont adoptées : découpage stratifié, pondération des classes (`class_weight="balanced"`) pour les modèles qui l'acceptent, et évaluation fondée sur le F1, le rappel et l'AUC. Le rééchantillonnage n'a pas été mis en œuvre ; la pondération, plus simple et sans risque de fuite, a été jugée suffisante.

2.6 Corrélations et visualisations

Les corrélations de Pearson sont calculées sur l'apprentissage, car elles servent à une décision (Figure 2, y compris la corrélation avec la cible).

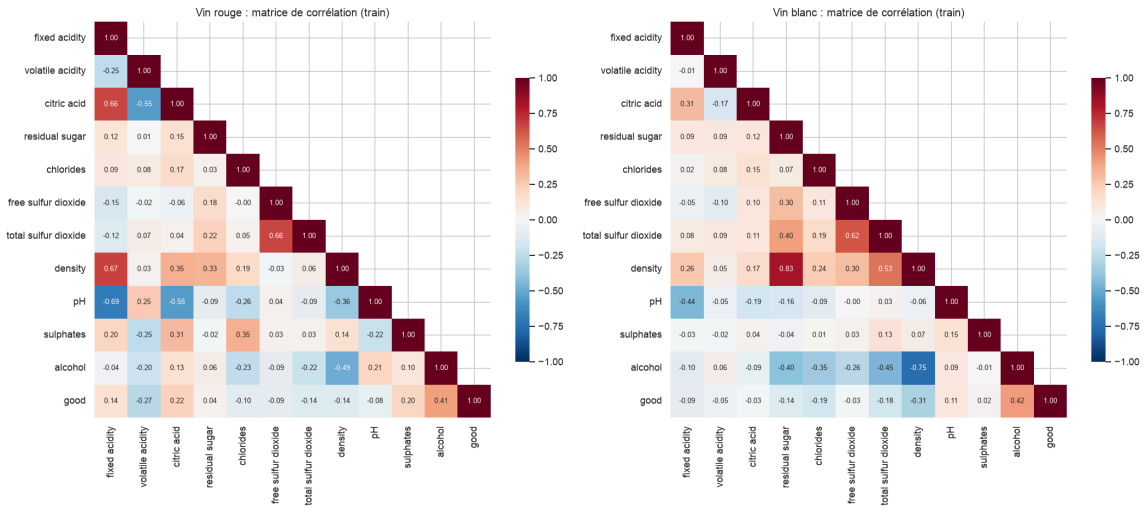


Figure 2 – Matrices de corrélation sur l'apprentissage (vin rouge à gauche, vin blanc à droite)

L'alcool est la variable la plus liée à la cible (r = 0,41 en rouge, 0,42 en blanc). Viennent ensuite l'acidité volatile (−0,27), l'acide citrique (0,22) et les sulfates (0,20) en rouge ; la densité (−0,31), les chlorures (−0,19) et le SO_2 total (−0,18) en blanc. Une seule paire dépasse le seuil de redondance de 0,8 : sucre résiduel et densité en blanc (r = 0,83), la densité étant aussi liée à l'alcool (r = −0,75). En rouge, les plus fortes corrélations (0,66 à 0,69 en valeur absolue) relient l'acidité fixe à l'acide citrique, à la densité et au pH. Ces redondances pénalisent surtout Naive Bayes (hypothèse d'indépendance) et rendent instables les coefficients de la régression logistique.

Histogrammes et boîtes à moustaches ont été produits pour chaque variable et chaque type (`figures/histograms_*.png`, `boxplots_*.png`) ; la Figure 3 montre ceux du vin rouge selon la classe.

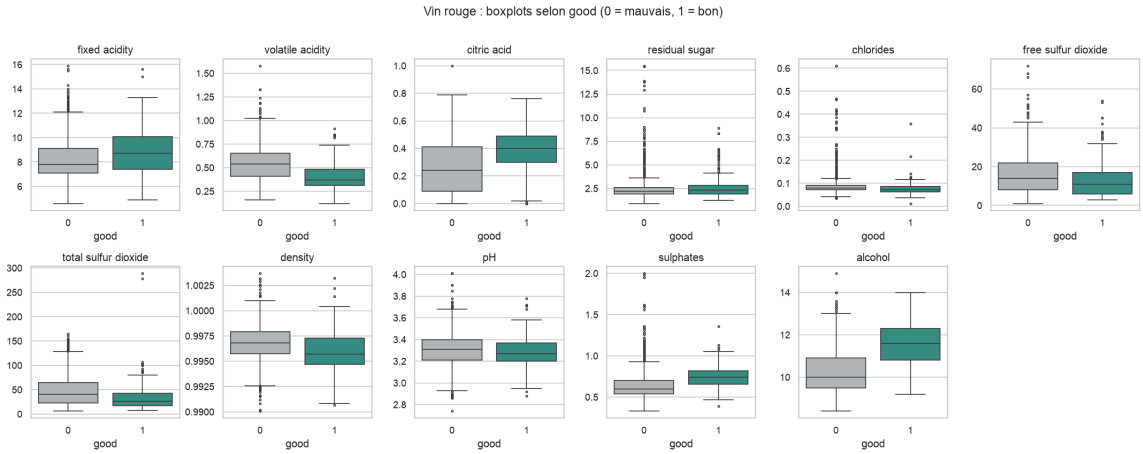


Figure 3 – Boîtes à moustaches des variables du vin rouge selon la classe (0 = mauvais, 1 = bon)

L'alcool sépare le mieux les classes (médiane nettement plus élevée chez les bons vins). En rouge, les bons vins ont moins d'acidité volatile et plus de sulfates ; en blanc, une densité et des chlorures plus faibles. Pour les autres variables, les boîtes se chevauchent largement : aucune variable ne suffit seule à prédire la classe.

2.7 Sélection de variables

Trois méthodes de familles différentes sont comparées par validation croisée stratifiée à 5 plis : un filtre de corrélation (retrait de la variable la plus redondante de chaque paire au-delà de 0,8), un filtre univarié `SelectKBest` (F de l'ANOVA et information mutuelle) et une méthode embarquée L1 (`SelectFromModel` avec une régression logistique L1, C = 0,1). Les sélecteurs à paramètres appris sont placés dans le pipeline. Pour `SelectKBest`, k est la plus petite valeur dont le F1 moyen reste à moins de 0,01 du meilleur (Tableau 5).

Tableau 5 – Méthodes de sélection de variables (F1 et AUC moyens, validation croisée 5 plis) ; LR = régression logistique, NB = Naive Bayes

Méthode	Nb var.	F1 LR	F1 NB	AUC LR	AUC NB	Nb var.	F1 LR	F1 NB	AUC LR	AUC NB
	Vin rouge					Vin blanc				
Toutes les variables	11	0,508	0,524	0,872	0,848	11	0,558	0,537	0,822	0,802
Filtre de corrélation	11	0,508	0,524	0,872	0,848	10	0,564	0,525	0,817	0,809
SelectKBest ANOVA	8	0,509	0,512	0,871	0,848	8	0,545	0,536	0,813	0,793
SelectKBest info. mutuelle	7	0,508	0,524	0,870	0,850	9	0,548	0,530	0,811	0,798
L1 (C = 0,1)	8	0,509	0,530	0,874	0,858	11	0,557	0,533	0,822	0,801

Avec onze variables seulement, aucune méthode ne se détache : les écarts de F1 (≈ 0,01) restent inférieurs à l'écart-type entre plis (0,02 à 0,06). Le bénéfice est d'obtenir la même performance avec moins de variables. En rouge, la sélection L1 conserve huit variables sans perte et est la meilleure configuration pour Naive Bayes. En blanc, le retrait de la densité améliore le F1 de la régression logistique et l'AUC de Naive Bayes. Les variables retenues par presque toutes les méthodes sont l'alcool, l'acidité volatile, les sulfates et le SO_2 total en rouge ; l'alcool, l'acidité volatile, les chlorures, le sucre résiduel et le SO_2 total en blanc. Le choix de la sélection est intégré à la recherche d'hyperparamètres (§ 5).

2.8 Protocole expérimental et prévention des fuites

- graine aléatoire fixe (`SEED = 42`) pour toutes les étapes aléatoires ;
- découpage apprentissage/test stratifié 80/20 (Tableau 1), réalisé après les seules étapes sans état (dédoublonnage, création de la cible) ; la proportion de bons vins est identique à 0,1 point près entre les deux ;
- normalisation, sélection de variables et pondération apprises uniquement dans un `Pipeline`, réajusté dans chaque pli ;
- toute analyse servant à une décision (asymétrie, corrélations, sélection, seuil) calculée sur l'apprentissage seulement ;
- jeu de test utilisé une seule fois, pour l'évaluation finale du modèle retenu (§ 5.6).

3 Modélisation

3.1 Choix et justification des modèles

Les modèles de l'énoncé couvrent deux types de frontière : linéaire (régression logistique, Naive Bayes gaussien, SVM linéaire) et non linéaire (k-NN, arbre de décision, SVM à noyau gaussien RBF) ; le SVM est décliné avec les deux noyaux. Comparer les deux familles indique si la qualité s'explique par une combinaison pondérée des mesures ou par des interactions et effets de seuil. Le Tableau 6 justifie chaque choix au regard de ses propriétés et des données (continues, asymétriques, corrélées, bruitées).

Tableau 6 – Propriétés des modèles et adaptation aux données

Modèle	Frontière	Hypothèses / propriétés	Adaptation aux données
Régression logistique	Linéaire	Log-cote linéaire ; sortie probabiliste ; coefficients interprétables	Référence simple ; régularisation nécessaire face aux variables corrélées (densité, sucre, alcool)
Naive Bayes gaussien	Lin. / quadratique	Indépendance et normalité des variables dans chaque classe	Le logarithme rapproche les variables d'une loi normale ; indépendance violée par les variables corrélées
k-NN	Non linéaire, locale	Aucune hypothèse de forme ; vote des voisins	Très sensible à l'échelle (SO_2 total ≈ 100, chlorures ≈ 0,05) : standardisation indispensable
Arbre de décision	Non linéaire, seuils	Découpages successifs sur une variable	Insensible à l'échelle et robuste aux valeurs aberrantes ; mémorise le bruit sans contrainte
SVM linéaire	Linéaire	Maximisation de la marge (perte charnière)	Même frontière que la régression logistique, critère différent : contrôle de robustesse
SVM RBF	Non linéaire	Marge maximale dans l'espace du noyau gaussien	Capte des interactions ; sensible à l'échelle ; plus coûteux, acceptable ici (≤ 3 200 lignes)

La pondération des classes est appliquée à la régression logistique, à l'arbre et aux deux SVM ; Naive Bayes (qui estime les probabilités a priori) et le k-NN (qui ne l'accepte pas) en sont dépourvus. Un `DummyClassifier` fixe le plancher à dépasser. Toutes les variables sont conservées à ce stade.

3.2 Comparaison de base

Les modèles sont d'abord évalués avec leurs hyperparamètres par défaut, par validation croisée stratifiée à 5 plis sur l'apprentissage (Tableau 7).

Tableau 7 – Comparaison de base, hyperparamètres par défaut (moyennes sur 5 plis)

Modèle	AUC rouge	F1 rouge	AUC blanc	F1 blanc
Référence (classe majoritaire)	0,500	0,000	0,500	0,000
Régression logistique	0,872	0,508	0,822	0,558
Naive Bayes	0,848	0,524	0,802	0,537
k-NN (k = 5)	0,791	0,399	0,792	0,484
Arbre de décision	0,649	0,399	0,657	0,456
SVM linéaire	0,873	0,504	0,822	0,560
SVM RBF	**0,875**	0,523	**0,831**	**0,565**

Tous les modèles dépassent la référence. Les modèles linéaires atteignent déjà une AUC d'environ 0,87 (rouge) et 0,82 (blanc) ; le SVM RBF fait à peine mieux, avec un écart inférieur à l'écart-type entre plis (0,02 à 0,03). Le signal est donc essentiellement linéaire et monotone, cohérent avec les corrélations. Le k-NN et l'arbre sont les plus faibles par défaut. Tous les modèles s'entraînent en moins de 12 ms par pli, sauf le SVM RBF sur le blanc (≈ 63 ms).

3.3 Courbes de validation

Pour le k-NN et l'arbre, dont la complexité dépend surtout d'un paramètre, l'AUC d'apprentissage et de validation est tracée en fonction de ce paramètre (Figure 4).

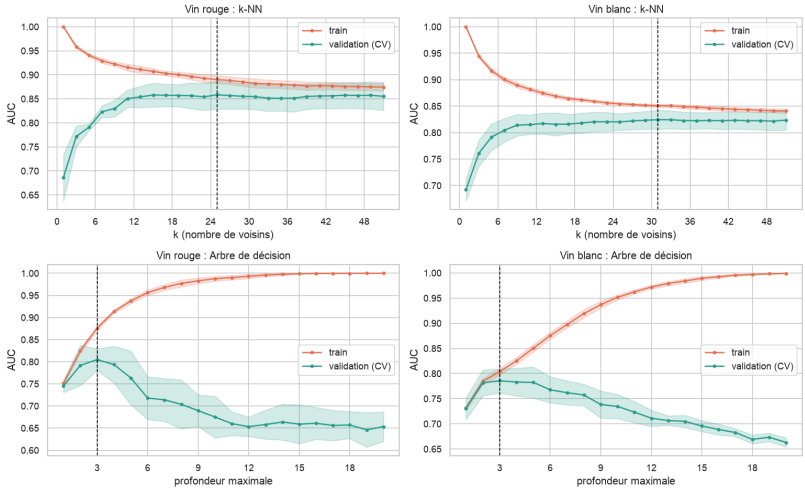


Figure 4 – Courbes de validation du k-NN (en haut, selon k) et de l'arbre (en bas, selon la profondeur) ; courbe supérieure : AUC d'apprentissage, inférieure : AUC de validation, ligne verticale : meilleure valeur

Pour le k-NN, k = 1 donne une AUC d'apprentissage de 1 et de validation ≈ 0,69 (variance maximale) ; la validation plafonne dès k ≈ 11 à 15, les meilleures valeurs étant k = 25 (rouge, AUC 0,858) et k = 31 (blanc, AUC 0,824). Pour l'arbre, le meilleur compromis est une profondeur de 3 (AUC 0,805 en rouge, 0,786 en blanc) ; au-delà, l'AUC d'apprentissage tend vers 1 et la validation diminue. Ces résultats définissent les plages de recherche du § 5.

4 Évaluation des modèles

4.1 Métriques et protocole

Les métriques de l'énoncé (accuracy, précision, rappel, F1, matrice de confusion, ROC et AUC) sont complétées par la spécificité, la balanced accuracy et l'average precision (AP, aire sous la courbe précision-rappel), plus exigeante que l'AUC quand les positifs sont rares. Le test étant réservé, les métriques sont calculées sur les prédictions hors-pli de la validation croisée à 5 plis : chaque vin de l'apprentissage est prédit une fois par un modèle qui ne l'a pas vu. Un k-NN (k = 25 ou 31) et un arbre de profondeur 3 issus des courbes de validation sont ajoutés ; leur score est légèrement optimiste, la complexité ayant été choisie sur les mêmes plis.

4.2 Résultats et matrices de confusion

Tableau 8 – Métriques hors-pli sur l'apprentissage, seuil par défaut (VP / FP / FN = effectifs des matrices de confusion)

Modèle	Acc.	Préc.	Rappel	F1	AUC	AP	VP / FP / FN
Vin rouge							
Référence	0,865	0,000	0,000	0,000	0,496	0,134	0 / 0 / 147
Régression logistique	0,790	0,372	0,803	0,509	0,871	0,485	118 / 199 / 29
Naive Bayes	0,842	0,441	0,639	0,522	0,849	0,414	94 / 119 / 53
k-NN (k = 5)	0,859	0,472	0,347	0,400	0,791	0,393	51 / 57 / 96
Arbre de décision	0,845	0,418	0,381	0,399	0,649	0,243	56 / 78 / 91
SVM linéaire	0,785	0,366	0,810	0,504	0,872	0,487	119 / 206 / 28
SVM RBF	0,810	0,396	0,769	0,523	0,873	0,531	113 / 172 / 34
k-NN (k = 25)	0,869	0,540	0,231	0,324	0,857	0,464	34 / 29 / 113
Arbre (profondeur 3)	0,753	0,332	0,823	0,474	0,808	0,371	121 / 243 / 26
Vin blanc							
Référence	0,792	0,000	0,000	0,000	0,500	0,208	0 / 0 / 660
Régression logistique	0,740	0,431	0,786	0,557	0,821	0,527	519 / 684 / 141
Naive Bayes	0,764	0,454	0,658	0,537	0,803	0,504	434 / 523 / 226
k-NN (k = 5)	0,808	0,551	0,430	0,483	0,792	0,467	284 / 231 / 376
Arbre de décision	0,774	0,457	0,456	0,456	0,657	0,322	301 / 358 / 359
SVM linéaire	0,738	0,431	0,797	0,559	0,821	0,530	526 / 695 / 134
SVM RBF	0,744	0,437	0,795	0,564	0,831	0,514	525 / 676 / 135
k-NN (k = 31)	0,823	0,651	0,323	0,432	0,824	0,530	213 / 114 / 447
Arbre (profondeur 3)	0,698	0,389	0,788	0,521	0,788	0,437	520 / 818 / 140

Le classifieur de référence obtient la meilleure accuracy sans identifier un seul bon vin : l'accuracy n'est pas pertinente ici. Les matrices de confusion (`figures/confusion_matrices_*.png`) montrent deux comportements. Les modèles pondérés (régression logistique, SVM, arbre de profondeur 3) retrouvent environ quatre bons vins sur cinq au prix de nombreux faux positifs : en rouge, la régression logistique annonce 199 faux bons vins pour 118 vrais. Les modèles non pondérés (k-NN, Naive Bayes) reconnaissent 87 % à 97 % des mauvais vins mais manquent beaucoup de bons vins. Le k-NN réglé illustre l'écart entre AUC et F1 : il classe bien (AUC 0,857) mais, au seuil par défaut, son rappel n'est que de 0,23. L'énoncé ne fixant pas le coût relatif des erreurs, l'équilibre précision/rappel (F1) est visé et le seuil est réglé au § 4.5.

4.3 Courbes ROC et précision-rappel

Les courbes ROC et précision-rappel de tous les modèles sont produites par le notebook (`figures/roc_pr_curves.png`) ; leurs aires sont les colonnes AUC et AP du Tableau 8. Très superposées, elles ne sont pas reproduites ici. Les courbes ROC de la régression logistique, des deux SVM et du k-NN réglé se confondent presque partout ; l'arbre non contraint, aux feuilles pures, ne produit quasiment qu'un point de fonctionnement. La courbe précision-rappel est plus discriminante : en rouge, le SVM RBF obtient la meilleure AP (0,531 contre 0,485 pour la régression logistique) ; en blanc, l'ordre s'inverse. Pour retrouver 80 % des bons vins, la précision tombe vers 0,35 en rouge et 0,42 en blanc pour tous les modèles, ce qui reflète la frontière floue entre les notes 6 et 7 plutôt que la limite d'un modèle particulier.

4.4 Comparaison des modèles et compromis biais/variance

Tous les modèles étant évalués sur les mêmes plis, l'AUC de chacun est comparée pli par pli à celle du meilleur (SVM RBF) : l'écart moyen est rapporté à l'écart-type des différences appariées (« rapport » ; < 1 = écart indiscernable du bruit de la validation croisée). Le diagnostic biais/variance repose sur l'AUC d'apprentissage, l'AUC de validation et leur écart, complétés par des courbes d'apprentissage (`figures/learning_curves.png`). Le Tableau 9 réunit les deux analyses.

Tableau 9 – Comparaison appariée au SVM RBF et diagnostic biais/variance avant réglage (AUC, 5 plis)

Modèle	Vin rouge				Vin blanc			
	Valid. (± é.-t.)	Rapport	App.	Écart	Valid. (± é.-t.)	Rapport	App.	Écart
SVM RBF	0,875 ± 0,035	–	0,948	0,073	0,831 ± 0,019	–	0,886	0,055
SVM linéaire	0,873 ± 0,032	0,09	0,889	0,015	0,822 ± 0,019	1,46	0,824	0,003
Régression logistique	0,872 ± 0,031	0,19	0,889	0,017	0,822 ± 0,018	1,43	0,825	0,003
k-NN (k = 25 / 31)	0,858 ± 0,030	1,10	0,890	0,032	0,824 ± 0,018	0,76	0,851	0,026
Naive Bayes	0,848 ± 0,032	1,34	0,873	0,025	0,802 ± 0,019	4,54	0,806	0,003
Arbre (profondeur 3)	0,805 ± 0,024	4,74	0,876	0,071	0,786 ± 0,024	2,64	0,804	0,018
k-NN (k = 5)	0,791	–	0,941	0,150	0,792	–	0,917	0,125
Arbre de décision	0,649 ± 0,028	7,96	1,000	0,351	0,657 ± 0,007	12,30	1,000	0,343

Comparaison. En rouge, SVM RBF, SVM linéaire et régression logistique sont indiscernables (rapport < 0,2). En blanc, le SVM RBF devance les modèles linéaires de 0,009 sur quatre plis sur cinq : avantage régulier mais inférieur à l'écart-type entre plis. Le meilleur modèle non linéaire gagne au plus 0,01 d'AUC.

Biais/variance. L'arbre non contraint illustre une variance pure (AUC 1,00 en apprentissage contre 0,65 en validation) ; le k-NN à k = 5 surapprend aussi. Les modèles linéaires ne surapprennent pas (écart ≤ 0,025) : leurs courbes d'apprentissage se rejoignent dès quelques centaines de vins puis plafonnent, leur limite étant le biais et le bruit d'étiquette. Le SVM RBF présente un peu de variance pour un gain non significatif. L'écart-type entre plis (≈ 0,03 en rouge, 0,02 en blanc) indique que l'AUC finale sur le petit test rouge sera incertaine d'au moins ± 0,03. Le meilleur compromis biais/variance est offert par la régression logistique et le SVM linéaire, au niveau du meilleur modèle avec la variance la plus faible.

4.5 Choix provisoire du modèle et seuil de décision

Règle de choix : meilleure AUC moyenne puis, parmi les modèles à moins d'un écart-type de celle-ci, le plus simple (ordre : régression logistique, Naive Bayes, SVM linéaire, arbre, k-NN, SVM RBF). Elle désigne la régression logistique pour les deux types. Le seuil par défaut (0,5) n'étant pas adapté à des classes déséquilibrées et pondérées, le seuil maximisant le F1 est choisi sur les prédictions hors-pli (Tableau 10).

Tableau 10 – Effet du seuil de décision sur la régression logistique (prédictions hors-pli)

Jeu	Seuil	Précision	Rappel	F1	VP / FP / FN
Vin rouge	0,50 (défaut)	0,372	0,803	0,509	118 / 199 / 29
Vin rouge	0,73 (F1 max)	0,487	0,653	0,558	96 / 101 / 51
Vin blanc	0,50 (défaut)	0,431	0,786	0,557	519 / 684 / 141
Vin blanc	0,52 (F1 max)	0,446	0,771	0,565	509 / 632 / 151

En rouge, le seuil élevé divise par deux les faux positifs et porte le F1 de 0,509 à 0,558, au prix d'une baisse du rappel ; en blanc, le gain est minime. Le seuil est choisi à nouveau après réglage (§ 5.5).

5 Optimisation des hyperparamètres

5.1 Protocole

Les hyperparamètres sont réglés par Grid Search pour les modèles dont l'espace est petit ou discret, et par Random Search (`RandomizedSearchCV`, 64 tirages log-uniformes) pour le SVM RBF, dont les deux paramètres continus couvrent plusieurs ordres de grandeur. La métrique optimisée est l'AUC, indépendante du seuil. La validation croisée interne utilise les mêmes 5 plis stratifiés ; logarithme, normalisation et sélection de variables font partie du pipeline et sont réappris dans chaque pli. Le meilleur score d'une recherche étant optimiste (hyperparamètres choisis sur les mêmes plis), les modèles optimisés sont évalués par **validation croisée imbriquée** (k-fold, 5 × 5 plis) : chaque pli externe relance la recherche sur les quatre autres et évalue le modèle réglé sur un pli jamais vu. Les modèles par défaut sont évalués sur les mêmes plis externes (comparaison appariée).

5.2 Espaces de recherche

Les plages proviennent des analyses précédentes : k-NN autour de k ≈ 25 à 31, arbres peu profonds, choix du scaler et de la méthode de sélection, C et gamma en échelle logarithmique. Pour l'arbre, les valeurs de `ccp_alpha` sont des quantiles du chemin d'élagage coût-complexité calculé sur l'apprentissage (Tableau 11).

Tableau 11 – Méthodes et espaces de recherche (nombre de candidats rouge / blanc)

Modèle	Méthode	Hyperparamètres	Candidats
Régression logistique	Grid Search	prétraitement, sélection, `C`, `l1_ratio`	88 / 176
Naive Bayes	Grid Search	prétraitement, sélection, `var_smoothing`	80 / 160
k-NN	Grid Search	scaler, `n_neighbors`, `weights`, `p`	120 / 120
Arbre de décision	Grid Search	`max_depth`, `min_samples_leaf`, `criterion`, `ccp_alpha`	320 / 320
SVM linéaire	Grid Search	`C`	11 / 11
SVM RBF	Random Search	`C`, `gamma`	64 / 64

5.3 Résultats du réglage et biais/variance après réglage

Tableau 12 – AUC par défaut → AUC imbriquée du modèle optimisé, et écart AUC apprentissage − validation avant → après réglage

Modèle	Vin rouge			Vin blanc		
	AUC défaut → réglé	Gain	Écart avant → après	AUC défaut → réglé	Gain	Écart avant → après
Régression logistique	0,877 → 0,874	−0,003	0,017 → 0,011	0,820 → 0,820	0,000	0,003 → 0,003
Naive Bayes	0,860 → 0,863	+0,003	0,025 → 0,021	0,802 → 0,803	+0,001	0,003 → 0,003
k-NN	0,810 → 0,867	+0,057	0,150 → 0,120	0,791 → 0,831	+0,040	0,125 → 0,165
Arbre de décision	0,636 → 0,822	+0,185	0,351 → 0,085	0,652 → 0,785	+0,133	0,343 → 0,045
SVM linéaire	0,877 → 0,875	−0,002	0,015 → 0,010	0,820 → 0,820	0,000	0,003 → 0,002
SVM RBF	0,868 → 0,860	−0,007	0,073 → 0,014	0,832 → 0,831	−0,001	0,055 → 0,016

Le réglage n'apporte rien aux modèles linéaires, dont les valeurs par défaut étaient déjà sur le plateau de performance : avec la pénalité L2, l'AUC de la régression logistique est quasi constante pour C entre 10^{-3} et 10^{2}. Le k-NN et l'arbre progressent nettement, sur les cinq plis externes. Les réglages retenus confirment les courbes de validation : k = 21 (rouge) ou 33 (blanc) voisins pondérés par la distance ; arbres de profondeur 6 (rouge) ou 5 (blanc) freinés par `min_samples_leaf` (20 ou 40) et par l'élagage. Pour le SVM RBF rouge, le `best_score_` (0,880) dépasse de 0,02 l'AUC imbriquée (0,860) : c'est l'optimisme que corrige la validation imbriquée.

Côté biais/variance, le réglage réduit fortement le surapprentissage de l'arbre et du SVM RBF, ce dernier obtenant le même score avec une variance comparable aux modèles linéaires. Pour le k-NN, l'AUC d'apprentissage vaut 1 car la pondération par la distance donne à chaque vin un voisin à distance nulle (lui-même) : l'écart est un artefact de ce paramètre, non un signe de mauvaise généralisation. Les modèles linéaires sont inchangés ; leur limite reste le biais, que le réglage ne peut corriger.

5.4 Comparaison de Grid Search, Random Search et Halving

Sur le SVM RBF, les deux méthodes sont comparées à budget égal (64 candidats, soit 320 apprentissages) : grille régulière 8 × 8 et 64 tirages aléatoires sur les mêmes plages. Une recherche par élimination successive (`HalvingRandomSearchCV`) est ajoutée (Tableau 13, Figure 5).

Tableau 13 – SVM RBF : comparaison des méthodes de recherche (AUC de la validation croisée interne)

Jeu	Méthode	Évaluations	Meilleure AUC	C	gamma	Temps (s)
Vin rouge	Grid Search 8 × 8	320	0,880	1,39	0,0193	1,2
Vin rouge	Random Search (64)	320	0,880	4,11	0,0051	1,0
Vin rouge	Halving Random Search	560	0,856	145,3	0,0007	1,4
Vin blanc	Grid Search 8 × 8	320	0,835	37,3	0,0052	7,6
Vin blanc	Random Search (64)	320	0,834	26,4	0,0058	6,7
Vin blanc	Halving Random Search	620	0,830	4,11	0,0051	2,4

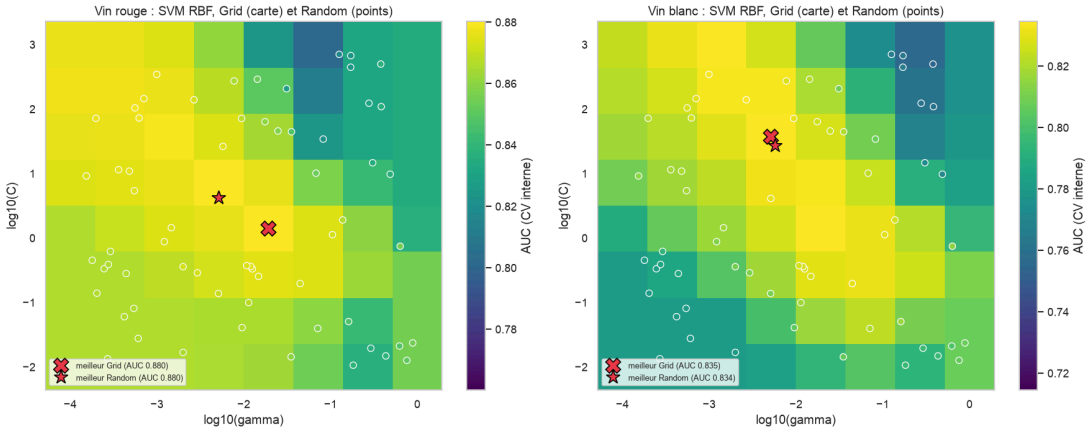


Figure 5 – AUC du SVM RBF selon log10(gamma) et log10(C) : carte de la grille (Grid Search) et points des tirages aléatoires (Random Search) ; vin rouge à gauche, vin blanc à droite

Grid Search et Random Search atteignent la même AUC pour le même coût. Leurs meilleurs points diffèrent mais se situent sur la même crête, où un gamma plus faible est compensé par un C plus grand. Le Random Search teste 64 valeurs distinctes de chaque paramètre contre 8 pour la grille et explore donc mieux un espace continu. Les deux retiennent un gamma faible, c'est-à-dire une frontière presque linéaire. L'élimination successive est trois fois plus rapide sur le blanc pour une AUC proche ; elle n'apporte rien sur le petit jeu rouge.

5.5 Choix du modèle final et du seuil

La règle du § 4.5, appliquée aux AUC imbriquées, désigne à nouveau la régression logistique pour les deux types : après réglage, tous les modèles sauf l'arbre sont à moins d'un écart-type du meilleur, et elle est la plus simple. Le seuil est choisi à nouveau sur les prédictions hors-pli du modèle réglé (Tableau 14). Les deux valeurs de C, très différentes, se situent toutes deux sur le plateau de performance : cet écart n'a pas de signification particulière.

Tableau 14 – Modèle final retenu (régression logistique, pénalité L2, toutes variables)

Jeu	C	AUC imbriquée	Seuil (F1 maximal)	F1 hors-pli (seuil défaut → choisi)
Vin rouge	0,0316	0,874	0,691	0,497 → 0,554
Vin blanc	31,6	0,820	0,537	0,558 → 0,564

5.6 Évaluation finale sur le jeu de test

Le modèle retenu est réappris sur tout l'apprentissage puis évalué une seule fois sur le test, au seuil choisi en validation croisée ; aucune décision n'est prise après cette étape (Tableau 15, Figure 6).

Tableau 15 – Évaluation finale : validation croisée hors-pli (apprentissage) et test

Métrique	Rouge CV	Rouge test	Blanc CV	Blanc test
Accuracy	0,849	0,864	0,758	0,762
Précision	0,462	0,500	0,451	0,457
Rappel	0,694	0,649	0,753	0,782
Spécificité	0,873	0,898	0,759	0,756
F1	0,554	**0,565**	0,564	**0,577**
Balanced accuracy	0,784	0,773	0,756	0,769
AUC	0,875	**0,892**	0,821	**0,835**
AP	0,493	0,569	0,527	0,589
VP / FP / FN / VN (test)	–	24 / 24 / 13 / 211	–	129 / 153 / 36 / 475

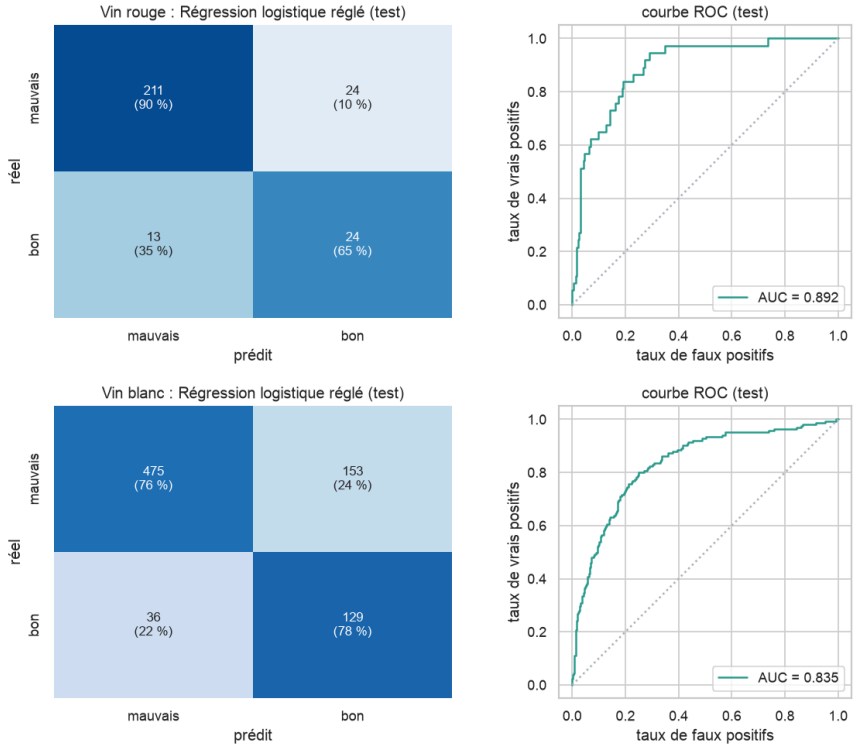


Figure 6 – Jeu de test, régression logistique réglée : matrice de confusion et courbe ROC (vin rouge en haut, vin blanc en bas)

En rouge, le modèle retrouve 24 des 37 bons vins (rappel 0,65) et la moitié des vins annoncés bons le sont (précision 0,50). En blanc, il retrouve 129 bons vins sur 165 (rappel 0,78) avec une précision de 0,46. Les scores de test sont légèrement supérieurs à ceux de la validation croisée et restent dans la marge d'incertitude annoncée (± 0,03 d'AUC en rouge, ± 0,02 en blanc) : aucun surapprentissage du réglage n'est observé, et les estimations par validation croisée étaient fiables.

6 Discussion et limites

- **Frontière floue entre les notes 6 et 7.** La note est une médiane d'évaluations d'experts et la classe 6, la plus nombreuse, jouxte le seuil : cette ambiguïté plafonne le F1 (≈ 0,56 à 0,58) quel que soit le modèle.
- **Taille du test rouge.** Avec 37 bons vins, un vin de plus ou de moins modifie le rappel de 2,7 points ; les scores de test rouges doivent être lus avec cette marge.
- **Quasi-doublons.** Seuls les doublons exacts sont supprimés ; des vins quasi identiques peuvent subsister de part et d'autre du découpage.
- **Optimisme résiduel.** Le seuil est choisi sur les mêmes plis que les hyperparamètres ; le F1 hors-pli est donc légèrement optimiste, ce que l'évaluation unique sur le test permet de contrôler.
- **Coût des erreurs non spécifié.** Le seuil maximise le F1 ; un autre point de fonctionnement serait choisi si les coûts d'un faux positif et d'un faux négatif étaient connus.
- **Rééchantillonnage non testé.** SMOTE et la sélection de variables par transformateur personnalisé dans chaque pli n'ont pas été mis en œuvre ; ce sont des extensions possibles.

7 Éléments bonus et reproductibilité

Tableau 16 – État des éléments bonus

Élément bonus	État	Détail
Publication sur GitHub ou GitLab	Réalisé	Dépôt public : https://github.com/kazoj/tpml
Tests unitaires	Réalisé	15 tests pytest (dossier tests/) : chargement, nettoyage, découpage, prétraitement, métriques.
Conteneurisation Docker	Réalisé	Dockerfile (Python 3.11, JupyterLab) ; commandes de construction et d'exécution dans le README.
Application web de prédiction	Non réalisé	Aucune application web n'est présente dans le dépôt.

La reproductibilité est assurée par la graine fixe (`SEED = 42`), les versions figées des bibliothèques (`requirements.txt` : scikit-learn 1.9.1, pandas 3.0.6, numpy 2.4.6, etc.) et l'image Docker, construite avec `docker build -t wine-quality .` et lancée avec `docker run --rm -p 127.0.0.1:8888:8888 wine-quality` ; JupyterLab étant lancé sans jeton d'accès, le port n'est publié que sur l'adresse locale. Le notebook peut aussi être réexécuté intégralement sans interface (≈ 3 minutes) avec `nbconvert`.

8 Conclusion

Ce projet a permis de construire, pour chaque type de vin, un classifieur binaire de la qualité selon un protocole sans fuite de données : dédoublonnage préalable, découpage stratifié, pipeline réappris dans chaque pli, choix effectués sur l'apprentissage seulement et test utilisé une seule fois. L'analyse montre que le signal est essentiellement linéaire et porté en premier lieu par la teneur en alcool. Après optimisation par Grid Search et Random Search et évaluation par validation croisée imbriquée, aucun modèle ne se détache significativement de la régression logistique, retenue pour sa simplicité, son absence de surapprentissage et son interprétabilité. Sur le test, elle atteint une AUC de 0,892 et un F1 de 0,565 pour le vin rouge, et une AUC de 0,835 et un F1 de 0,577 pour le vin blanc, en accord avec les estimations par validation croisée. Le principal facteur limitant est la frontière peu marquée entre les notes 6 et 7, plutôt que le choix ou le réglage du modèle.

Annexe A – Tableau de conformité à l'énoncé

Chaque exigence de l'énoncé, la section du rapport qui la traite et la diapositive de soutenance correspondante.

Tableau 17 – Conformité aux exigences de l'énoncé

Exigence de l'énoncé	Rapport	Soutenance	Statut
2.1 Chargement et statistiques descriptives	§ 1.2, 2.1	Diapo 2	Traité
2.1 Valeurs manquantes	§ 2.2	Diapo 3	Traité
2.1 Valeurs aberrantes	§ 2.3	Diapo 3	Traité
2.1 Encodage des variables catégorielles	§ 2.4	–	Traité
2.1 Cible binaire (qualité ≥ 7)	§ 2.5	Diapo 2	Traité
2.1 Distribution et traitement du déséquilibre	§ 1.2 (Tab. 1), 2.5	Diapos 2, 3	Traité
2.1 Analyse des corrélations	§ 2.6	Diapo 4	Traité
2.1 Matrice de corrélation, histogrammes, boxplots	§ 2.6 (Fig. 2, 3)	Diapo 4	Traité
2.1 Sélection de variables	§ 2.7	Diapo 4	Traité
2.1 Graine, découpage stratifié, pipeline	§ 2.8	Diapo 3	Traité
2.2 Modèles : LogReg, k-NN, arbre, NB, SVM	§ 3.1, 3.2	Diapo 6	Traité
2.2 Justification théorique (linéaire / non linéaire)	§ 3.1	Diapo 6	Traité
2.2 Adaptation au type de données	§ 3.1 (Tab. 6)	–	Traité
2.3 Accuracy, précision, rappel, F1	§ 4.1, 4.2	Diapo 5	Traité
2.3 Matrice de confusion	§ 4.2, 5.6	Diapo 8	Traité
2.3 Courbe ROC et AUC	§ 4.3, 5.6	Diapos 5, 8	Traité
2.3 Comparaison et interprétation	§ 4.4	Diapo 6	Traité
2.3 Compromis biais/variance	§ 3.3, 4.4, 5.3	Diapos 6, 7	Traité
2.4 Grid Search	§ 5.1 à 5.4	Diapo 7	Traité
2.4 Random Search	§ 5.1, 5.4	Diapo 7	Traité
2.4 Évaluation par validation croisée k-fold	§ 5.1, 5.3	Diapos 5, 7	Traité
2.5 Bonus : GitHub / GitLab	§ 7	Diapo 9	Traité
2.5 Bonus : tests unitaires	§ 7	Diapo 9	Traité
2.5 Bonus : Docker	§ 7	Diapo 9	Traité
2.5 Bonus : application web	§ 7	Diapo 9	Non réalisé
3 Livrable : rapport technique	Présent document	–	Traité
3 Livrable : notebook Python	§ 1.3, 7	–	Traité (projet.ipynb)